

SCC0282 – Recuperação de Informação

Trabalho Prático 1

Sistema de recuperação textual sobre a coleção Cranfield

Gabriel Hyppolito – 14571810

ICMC – Universidade de São Paulo

`gabriel.hyppolito@usp.br`

Setembro de 2026

1 Introdução

A Recuperação de Informação (RI) trata do problema de, dada uma consulta em linguagem natural, ordenar um conjunto de documentos de acordo com sua relevância para essa consulta. Este trabalho tem como objetivo implementar e avaliar dois modelos clássicos de RI – o Modelo Vetorial (TF-IDF com similaridade do cosseno) e o Modelo Probabilístico BM25 – sobre a coleção Cranfield, comparando diferentes estratégias de pré-processamento, parametrização do BM25 e formulações de consulta, sempre por meio de métricas de avaliação padrão da área (Precision@10, Recall@10, MAP e MRR). Além da comparação quantitativa entre os dois modelos, o trabalho investiga, com exemplos concretos, os motivos pelos quais cada modelo se sai melhor ou pior em consultas específicas, relacionando esse comportamento a conceitos como frequência de termos, raridade (IDF), tamanho de documento e saturação de frequência.

2 Técnicas Utilizadas

2.1 Pré-processamento

O texto de documentos e consultas passa por: tokenização (NLTK `word_tokenize`), normalização para minúsculas, remoção de tokens não alfabéticos (pontuação/números) e, opcionalmente, remoção de stopwords (lista padrão do NLTK em inglês) e stemming (SnowballStemmer). Foram comparadas 4 configurações: *nada* (só tokenização/lowercase), *stopwords*, *stemming* e *ambas* (stopwords + stemming).

2.2 Modelo Vetorial

Documentos e consultas são representados como vetores de pesos TF-IDF no mesmo espaço vetorial (`sklearn.TfidfVectorizer`, ajustado apenas na coleção de documentos; a consulta é apenas *transformada* nesse espaço, sem recalculer o IDF). O score de um documento D para uma consulta Q é a similaridade do cosseno entre os dois vetores:

$$\text{score}(D, Q) = \cos(\vec{D}, \vec{Q}) = \frac{\vec{D} \cdot \vec{Q}}{\|\vec{D}\| \|\vec{Q}\|}$$

Cada componente do vetor é o peso TF-IDF do termo no documento (ou consulta). O `TfidfVectorizer` é usado com os parâmetros padrão do scikit-learn (`smooth_idf=True`, `norm='l2'`), portanto o IDF efetivamente calculado é o suavizado $\text{idf}(t) = \ln\left(\frac{1+N}{1+\text{df}(t)}\right) + 1$ (o “+1” no numerador e denominador

evita divisão por zero para termos ausentes da coleção de treino e evita que um termo presente em todos os documentos receba IDF nulo). A normalização pelo cosseno faz com que o score dependa da *proporção* de termos em comum, não da contagem bruta – por isso documentos mais longos não são automaticamente favorecidos.

2.3 Modelo Probabilístico (BM25)

Implementado explicitamente (sem biblioteca que esconda o cálculo). Para cada termo q_i da consulta presente no documento D :

$$\text{score}(D, Q) = \sum_{q_i \in Q} \text{IDF}(q_i) \cdot \frac{f(q_i, D) (k_1 + 1)}{f(q_i, D) + k_1 (1 - b + b \frac{|D|}{\text{avgdl}})}, \quad \text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$

onde $f(q_i, D)$ é a frequência do termo no documento, $|D|$ o tamanho do documento, avgdl o tamanho médio dos documentos da coleção, $n(q_i)$ o número de documentos que contêm o termo, e k_1, b hiperparâmetros que controlam, respectivamente, a saturação da frequência de termo e a força da normalização por tamanho do documento ($b=0$ ignora o tamanho do documento; $b=1$ normaliza totalmente).

3 Avaliação

Dataset: coleção Cranfield, obtida via `ir_datasets`: 1400 documentos, 225 consultas e 1837 julgamentos de relevância (1612 marcados como relevantes, grau ≥ 1). Julgamentos com valor -1 e documentos não julgados foram tratados como não relevantes, conforme especificado no enunciado.

Métricas: Precision@10, Recall@10, MAP (Mean Average Precision, calculado sobre o ranking completo) e MRR (Mean Reciprocal Rank) como métrica adicional. Resultados mantidos por consulta e agregados (média).

Configuração experimental: a configuração de pré-processamento *ambas* (stopwords + stemming) foi fixada como padrão a partir da Seção 4.2 em diante, por ter obtido o maior MAP no experimento de pré-processamento (Seção 4.1). O BM25 usa $k_1=1,2$, $b=0,75$ como parâmetros padrão fora da Seção 4.4 (que varia justamente esses valores).

4 Resultados Obtidos e Análise

4.1 Pré-processamento

Configuração	Precision@50	Recall@50	MAP	MRR
nada	0,0717	0,5552	0,2385	0,4778
stopwords	0,0744	0,5773	0,2473	0,4781
stemming	0,0788	0,6028	0,2607	0,4922
ambas	0,0807	0,6245	0,2711	0,5036

Tabela 1: Comparação das 4 configurações de pré-processamento (Modelo Vetorial).

A configuração *ambas* obteve o melhor resultado em todas as métricas. Comparando os ganhos isolados sobre a linha de base (*nada*), o *stemming* contribui mais que a remoção de *stopwords* para o MAP (+9,3% vs. +3,7%): o stemming normaliza variações morfológicas (plural, tempos verbais, sufixos técnicos) muito comuns no vocabulário científico do Cranfield, aumentando o casamento léxico entre consulta e documento por termo-raiz; já a remoção de stopwords elimina ruído, mas termos muito frequentes já recebem IDF baixo no TF-IDF, então seu impacto isolado é menor. O

ganho de *ambas* (+13,7%) é maior que a soma dos efeitos isolados, sugerindo um efeito complementar entre as duas técnicas.

4.2 Modelo Vetorial vs. BM25

Modelo	Precision@10	Recall@10	MAP	MRR
Vetorial	0,2191	0,3657	0,2711	0,5036
BM25	0,2160	0,3631	0,2841	0,5137

Tabela 2: Comparação agregada entre Modelo Vetorial e BM25 ($k_1=1,2$, $b=0,75$).

As médias são próximas: o Vetorial leva ligeira vantagem em Precision@10 e Recall@10, enquanto o BM25 tem MAP e MRR maiores (+4,8% e +2,0% relativos). Isso por si só não é suficiente para declarar um vencedor – olhando a diferença de AP por consulta (Tabela 3), há casos com diferença de até 0,73, muito maior que a diferença média das agregadas, o que mostra que os modelos divergem fortemente *consulta a consulta*, mesmo com médias parecidas.

Consulta	AP Vetorial	AP BM25	Diferença (BM25–Vetorial)
81	0,267	1,000	+0,733
154	0,583	1,000	+0,417
173	0,583	1,000	+0,417
178	0,642	0,167	−0,475
145	0,591	0,177	−0,414

Tabela 3: As 5 consultas com maior diferença absoluta de AP entre os modelos.

4.3 Análise por Consulta

Foram selecionadas 6 consultas: duas onde o BM25 é claramente superior, duas onde o Vetorial é superior, e duas onde ambos têm desempenho insatisfatório ($AP < 0,10$ em ambos).

Caso	Consulta (id)	Modelo	Top-5 (doc, * = relevante)	AP
BM25 $\gg$ Vetorial	81	Vetorial	249, 652, 206, 714, 672*	0,267
	81	BM25	799*, 672*, 468, 631, 714	1,000
Vetorial $\gg$ BM25	178	Vetorial	591*, 589*, 216, 543, 138	0,642
	178	BM25	543, 31, 426, 592, 138	0,167
Ambos insatisfatórios	31	Vetorial / BM25	751, 68/1209, 247/1153, 918, 780/895	0,001
	22	Vetorial / BM25	125, 254/560, 560/413, 413/307, 346/254	0,002

Tabela 4: Top-5 de documentos retornados por cada modelo nas 6 consultas selecionadas, com relevância indicada por *.

Consulta 81 (*wind-tunnel corrections for a two-dimensional aerofoil mounted off-centre*): o BM25 chega a $AP=1,0$, colocando os dois documentos relevantes (799 e 672) nas duas primeiras posições, enquanto o Vetorial só encontra um deles na 5ª posição. O motivo é a normalização por tamanho: o BM25 dá grande peso a termos raros como “*tunnel*” e “*interference*” nesses dois documentos curtos, sem que a similaridade seja diluída pelos demais termos do vetor – efeito que o cosseno do Vetorial, ao normalizar pelo vetor inteiro, atenua.

Consulta 178 (*axial compressor choking line*) tem 4 documentos relevantes na coleção (591, 589, 590, 588). O Vetorial acerta dois deles (591, 589) nas duas primeiras posições ($AP=0,642$). O BM25 os perde do Top-5 ($AP=0,167$), preferindo o documento 543 (não relevante, sobre “*compressor stage*”).

characteristics”); mas o quadro não é de falha total: o documento 589 reaparece na posição 6 e o documento 590 na posição 9, ambos ainda dentro do Top-10 – é por isso que o AP do BM25 não cai a zero. Apenas 591 (posição 21) e 588 (posição 29) de fato desaparecem do ranking. As duas quedas têm causas distintas: o documento 591 casa apenas com o termo “*compressor*” ($tf=3$) entre os 7 termos da consulta, enquanto concorrentes como o 543 casam parcialmente com mais termos, mesmo com menor frequência individual – pouca cobertura léxica pesa mais que uma única ocorrência forte. Já o documento 589 tem a maior frequência de “*compressor*” entre os documentos do Top-10 ($tf=13$), mas também é o mais longo (129 tokens, $1,52\times$ o avgdl= 84,97): a saturação de frequência do BM25 ($k_1=1,2$) já limita boa parte do ganho marginal dessas 13 ocorrências, e a normalização por tamanho ($b=0,75$) ainda penaliza o excesso de comprimento, permitindo que documentos curtos e sem essa penalização, como o 543 (44 tokens, $tf=5$), cheguem perto do seu score mesmo com bem menos ocorrências do termo. O cosseno do Vetorial, por não impor saturação de frequência e normalizar apenas pelo tamanho do vetor (não pelo comprimento do texto), recompensa de forma mais direta a alta concentração do termo em 589, mantendo-o nas primeiras posições.

Consultas 31 e 22 (ambas com $AP \approx 0,001\text{--}0,002$ nos dois modelos): em nenhum dos casos o documento relevante aparece perto do topo. Isso indica *divergência de vocabulário* entre consulta e documento relevante – como os dois modelos são *bag-of-words* puro, nenhum recupera sinônimos ou paráfrases; se o documento relevante usa termos diferentes dos da consulta, ambos falham da mesma forma, o que também explica por que a diferença entre os modelos é próxima de zero nesses casos (ambos “erram igual”).

4.4 Variação dos Parâmetros do BM25




Figura 1: MAP para cada combinação de $k_1 \in \{0,5; 1,2; 2,0\}$ e $b \in \{0; 0,75; 1\}$. Eixo y recortado em $[0,24; 0,30]$ para tornar visíveis as diferenças entre curvas (todas as combinações têm MAP nessa faixa estreita).

A melhor combinação foi $k_1=2,0$, $b=0,75$ (MAP= 0,2934, Precision@10= 0,2218). Dois efeitos ficam claros na Figura 1: (1) aumentar k_1 (menos saturação da frequência de termo) melhora o MAP em todos os valores de b , indicando que repetições adicionais de um termo ainda carregam informação de relevância nesta coleção; (2) o salto de $b=0$ para $b=0,75$ é grande (ex.: MAP 0,2597 $\rightarrow$ 0,2934 em $k_1=2,0$), mostrando que os documentos do Cranfield variam bastante em tamanho e que ignorar essa variação ($b=0$) prejudica o ranking; já ir de $b=0,75$ para $b=1$ (“*todo*” a normalização) tem efeito pequeno e às vezes negativo (MAP cai de 0,2934 para 0,2876 em $k_1=2,0$), sugerindo que a normalização total penaliza demais alguns documentos relevantes que são naturalmente mais longos.

A consulta mais afetada pela variação de b (com $k_1=2,0$ fixo) foi a consulta 6. Em $b=0$ o documento relevante 99 aparece no Top-10 (posição 10); ao ligar a normalização ($b \geq 0,75$) ele desaparece do Top-10. A causa é direta: o documento 99 tem 154 tokens, $1,81\times$ o tamanho médio

da coleção (avgdl=84,97) – exatamente o perfil que a normalização por b penaliza. Já o documento 257 (também relevante, 111 tokens, $1,31 \times$ a média) permanece no Top-10 em todos os valores de b : ele contém o termo raro “*couett*” (presente em apenas 10 documentos da coleção, IDF= 4,89), cuja contribuição isolada ao score (4,35) é grande o suficiente para superar a penalização de tamanho.

4.5 Modificação de Consultas

Consulta	Estratégia	Docs. trocados – Vetorial	Docs. trocados – BM25
1	muitos sinônimos	9/10	9/10
5	sinônimo (3 termos)	7/10	5/10
9	mais genérica (remove termo)	4/10	2/10
30	mais específica (acrescenta)	4/10	5/10
180	acrescenta termo pouco discriminativo	1/10	1/10

Tabela 5: Quantidade de documentos que entraram/saíram do Top-10 ao comparar a consulta original com a modificada.

Consulta 1 (troca de praticamente todo o vocabulário de conteúdo por sinônimos, ex. “*aeroelastic*” → “*aero-structural*”, “*heated*” → “*thermally loaded*”) é a consulta com 28 documentos relevantes na coleção – de longe a mais genérica das 5 – e provoca a maior mudança possível no Top-10: 9 dos 10 documentos são substituídos em ambos os modelos. Isso derruba o desempenho (Vetorial: AP 0,222 → 0,153, Precision@10 0,50 → 0,20; BM25: AP 0,186 → 0,145, Precision@10 0,30 → 0,20), incluindo a perda de 5 documentos relevantes do Top-10 do Vetorial (51, 12, 879, 56, 13) e 3 do BM25 (51, 12, 879). O resultado, no entanto, não é uma simples ortogonalização total: em *ambos* os modelos, 2 documentos relevantes que não apareciam no Top-10 original (184 e 880) passam a aparecer no Top-10 da consulta modificada. Ou seja, a troca de vocabulário não apenas quebra o casamento com os documentos que a formulação original encontrava, como também aproxima a consulta do vocabulário usado por *outros* documentos relevantes que a formulação original não alcançava – um efeito esperado numa consulta com pool de relevantes tão grande e heterogêneo, em que nenhuma formulação única cobre bem todo o vocabulário usado pelos avaliadores. Ainda assim, o saldo é negativo (mais relevantes perdidos do que ganhos), o que confirma que a mudança lexical, no agregado, prejudica mais do que ajuda – mas mostra que a limitação de modelos *bag-of-words* sem noção de semântica tem duas faces: perde casamentos válidos, mas também pode, por acaso, abrir caminho para outros.

Consulta 180 (acréscimo do termo pouco discriminativo “*temperature*”) tem o efeito oposto: apenas 1 documento trocado em cada modelo, e os 3 documentos relevantes (622, 616, 617) permanecem no Top-10 dos dois modelos antes e depois. Isso confirma que o *tamanho* da mudança lexical (quantos termos de conteúdo são alterados, e quão raros eles são) determina o quanto o ranking muda – adicionar um único termo moderadamente comum apenas reordena posições marginais, sem deslocar os documentos que já dominavam o score.

4.6 Análise de Erros

Tipo	Consulta / Doc	Tam. doc. (raz. a avgdl)	Evidência
Falso positivo	q7 / doc 492	32 (0,38)	“ <i>angl</i> ” tf=4, “ <i>attack</i> ” tf=4, “ <i>pressur</i> ” tf=4
Falso positivo	q137 / doc 952	64 (0,75)	“ <i>collaps</i> ” tf=3, “ <i>creep</i> ” tf=3 (raro, df=34)
Falso negativo	q222 / doc 400	39 (0,46)	“ <i>stiffen</i> ” tf=0 (único termo ausente)

Tabela 6: Casos de falso positivo (não relevante no topo) e falso negativo (relevante fora do Top-10), com BM25.

Os dois falsos positivos compartilham um padrão: são documentos **curtos** (bem abaixo da média de tamanho) em que os poucos termos presentes coincidem repetidamente com termos da consulta. Como o BM25 satura a frequência de termo em relação ao tamanho do documento, um documento curto com alta repetição de termos-chave (ex.: “*attack*” 4× em apenas 32 tokens no doc 492) recebe um score desproporcional ao seu real valor informacional – o texto é topicamente próximo, mas não foi julgado relevante pelos avaliadores originais, evidenciando que sobreposição lexical não implica relevância.

O falso negativo (consulta 222, documento 400) é o caso mais instrutivo: o documento aparece na posição **11** – fora do Top-10 por uma única posição. Ele contém *buckl* (tf=4), *plate* (tf=2) e *shear* (tf=2), mas **não** contém o termo “*stiffen*” (derivado de *stiffened*) presente na consulta. A ausência de um único termo – mesmo com forte presença dos demais – foi suficiente para derrubar o documento da faixa avaliada, mostrando a fragilidade de um modelo puramente lexical diante de pequenas variações terminológicas dentro do mesmo campo semântico.

5 Considerações Finais

As médias agregadas entre Modelo Vetorial e BM25 são próximas (diferença de MAP de $\sim 4,7\%$), mas essa proximidade esconde divergências fortes por consulta (até 0,73 de diferença de AP), explicadas por mecanismos estruturais distintos dos dois modelos: a normalização por tamanho de documento do BM25 favorece documentos curtos com termos raros bem concentrados, enquanto a normalização pelo cosseno do Vetorial penaliza a repetição excessiva de um único termo. O pré-processamento (stemming combinado com remoção de stopwords) trouxe o maior ganho isolado de todo o trabalho (+13,7% de MAP), superando o efeito de qualquer configuração de parâmetros do BM25 testada. A variação de k_1 e b confirmou que a saturação de frequência e a normalização por tamanho têm efeitos reais e mensuráveis nesta coleção, mas com retornos decrescentes ($b=1$ não supera $b=0,75$). Por fim, tanto a modificação de consultas quanto a análise de erros reforçam a mesma conclusão central: como modelos puramente lexicais (*bag-of-words*), Vetorial e BM25 dependem de sobreposição literal de vocabulário – sinônimos quebram o casamento, um único termo ausente pode derrubar um documento relevante do Top-10, e repetição de termos comuns em documentos curtos pode gerar falsos positivos.

6 Uso de Ferramentas de IA

Ferramentas de IA generativa foram utilizadas como apoio: (i) na programação do pipeline completo (carregamento de dados, pré-processamento, implementação do Modelo Vetorial e do BM25, cálculo de métricas e dos scripts de experimento para os 9 requisitos do trabalho), incluindo depuração e revisão de código; e (ii) na revisão deste relatório, a partir da execução real dos scripts de teste e da leitura direta dos resultados numéricos gerados a fim de conferir a veracidade dos dados tabulados e a reprodutibilidade dos testes, confirmando as análises realizadas. Nenhum valor apresentado foi inventado, todos constam nos arquivos CSV em **resultados/**.